

Final Project: Monitoreo de la cobertura superficial del Embalse de Tominé mediante imágenes Sentinel-2

Juan Diego Romero, Eduardo de Brigard, Juan Parrales, Samuel Beltrán

21 de Mayo del 2026

1 Introducción

En los últimos años, el cambio climático y la actividad humana han tenido un impacto significativo sobre los ecosistemas hídricos y las coberturas terrestres de los Andes colombianos. Monitorear estos cambios es fundamental para comprender las consecuencias ambientales y su evolución con el tiempo. En este proyecto nos centramos en el **Embalse de Tominé**, ubicado en el municipio de Guatavita, Cundinamarca, el cual constituye una fuente de abastecimiento hídrico de importancia regional.

Mediante el uso del software QGIS e imágenes satelitales Sentinel-2 L2A, se busca analizar los cambios en las coberturas del suelo (agua, vegetación, zona urbana y nube) para febrero de 2024, para clasificar y caracterizar la cobertura superficial del embalse de tominé.

2 Región de Interés (ROI) y Caso de Estudio

El caso de estudio seleccionado es el **Embalse de Tominé**, ubicado en el municipio de Guatavita, departamento de Cundinamarca, Colombia. Se trata de un embalse artificial de alta montaña andina con un paisaje heterogéneo que incluye cuerpos de agua, vegetación ripariana y tejido urbano disperso. El monitoreo se concentra en el escenario de post-evento crítico provocado por el Fenómeno de El Niño en el primer trimestre de 2024.

Ubicado en las coordenadas aproximadas **N 4.99°**, **O 73.82°** (WGS 84 / UTM zona 18N, EPSG:32618).

3 Metodología

El flujo metodológico se estructuró de manera independiente a las herramientas tradicionales de un software GIS, utilizando un pipeline automatizado en Python para el procesamiento numérico y el entrenamiento de los modelos de aprendizaje supervisado.

3.1 Fase 1: Definición del Problema y Adquisición de Datos

- **Fecha de análisis:** Escenario de post-evento crítico (12 de febrero de 2024).
- **Fuente de datos:** Imágenes ópticas multiespectrales Sentinel-2 L2A (ESA Copernicus).




Figure 1: Panel del Navegador de QGIS mostrando las bandas Sentinel-2 L2A cargadas para el escenario post-evento (2024-02-12) y la capa vectorial de polígonos de entrenamiento corregida.

Las bandas descargadas abarcan resoluciones espaciales de 10 m (B02, B03, B04, B08) y 20 m (B05, B06, B11, B12), en formato GeoTIFF de reflectancia superficial (Level-2A) bajo el sistema de referencia espacial WGS 84 / UTM zona 18N (EPSG:32618).

La Región de Interés (ROI) fue acotada geográficamente para optimizar el procesamiento computacional. Dentro de esta zona, se digitalizaron manualmente polígonos de entrenamiento generosos y robustos distribuidos en **4 clases oficiales**: agua,

vegetacion, nube y urbano. La clase roca fue descartada debido a que los suelos desnudos y las playas expuestas por la sequía presentaban una respuesta espectral que se confundía con el tejido urbano, decidiéndose agruparlos para evitar ruido en las matrices de confusión.

Distribución de polígonos de entrenamiento

Table 1: Polígonos de entrenamiento por clase de cobertura (Dataset ampliado).

Clase	Polígonos	Descripción
agua	3	Cuerpos de agua abiertos y profundos en el centro del embalse
vegetacion	4	Parches extensos de bosques andinos y pastizales
nube	4	Áreas de nubosidad densa presentes en la escena
urbano	2	Cascos urbanos consolidados (Sesquilé y Guatavita)
Total	13	

Creación del dataset – Extracción de firmas espectrales

Se desarrolló un script de Python (`QGIS-Numerical.py`) utilizando las librerías `rasterio` y `geopandas` para automatizar la extracción de firmas espectrales de los píxeles puros contenidos en las geometrías vectoriales. El script realizó la reproyección al vuelo, el remuestreo bilingüe de las bandas de 20 m a 10 m, y calculó mediante la transformación afín las coordenadas geográficas (`EPSG:4326`) de cada celda.

Como resultado del rediseño de los polígonos, se generó un dataset robusto para el escenario de post-evento:

Table 2: Dataset de entrenamiento definitivo generado para el post-evento.

Archivo	Fecha	Total Píxeles	Columnas
entrenamiento_ano2_2024_final.tsv	2024-02-12	1,927	11

La distribución de las muestras garantiza un volumen más adecuado de información para mitigar el riesgo de sobreajuste (*overfitting*) en la fase algorítmica:

Table 3: Conteo de píxeles por clase de cobertura del suelo (Dataset 2024).

Clase	Píxeles Extraídos	Porcentaje (%)
vegetacion	814	42.2
agua	620	32.2
urbano	298	15.5
nube	195	10.1
Total	1,927	100.0

4 Fase 2: Preprocesamiento y Entrenamiento de Modelos

Dataset final de entrenamiento

Para la Fase 2 se consolidó un único dataset de entrenamiento denominado `datos_entrenamiento_sesquile_finales.tsv`, compuesto por **1,927 registros** y 11 columnas (Latitude, Longitude, B02, B03, B04, B05, B06, B08, B11, B12, clase). El dataset cubre cuatro clases de cobertura del suelo, cuya distribución se presenta en la Tabla 4.

Table 4: Distribución de clases en el dataset final de entrenamiento.

Clase	Píxeles	%
vegetacion	1,049	54.44
agua	746	38.71
nube	105	5.45
urbana	27	1.40
Total	1,927	100

Se observa un desbalance notable en la clase `urbana` (1.40 % del total), lo cual fue abordado mediante dos estrategias complementarias: aplicación de *pesos inversamente proporcionales a la frecuencia de clase* en el Árbol de Decisión, y *upsampling automático* en el `trainControl` de `caret` para los modelos KNN, SVM, ANN y Naive Bayes.

División train/test y normalización

El dataset fue dividido en un 80 % para entrenamiento (1,543 registros) y un 20 % para prueba (384 registros) mediante partición estratificada, garantizando que la proporción de clases se mantuviera en ambos subconjuntos. Para los modelos sensibles a la escala (KNN, SVM y ANN) se aplicó normalización *center + scale* calculada sobre el conjunto de entrenamiento y aplicada al conjunto de prueba.

Optimización de hiperparámetros (HPO)

Cada modelo fue sometido a una búsqueda exhaustiva de hiperparámetros mediante *GridSearchCV* con validación cruzada de 5 iteraciones (*5-fold CV*). La Tabla 5 resume los hiperparámetros explorados y los valores óptimos encontrados para cada arquitectura.

Table 5: Hiperparámetros explorados y valores óptimos por modelo.

Modelo	Parámetro	Valores explorados	Óptimo
Decision Tree	cp	0.0001, 0.001, 0.005, 0.01, 0.05, 0.1	0.0010
KNN	k	3, 5, 7, 9, 11, 15, 21, 31	3
SVM	C	0.1, 1, 10	10
	sigma	0.01, 0.1, 1	1.00
ANN	size	5, 10, 20	20
	decay	0.001, 0.01, 0.1	0.001
Naive Bayes	usekernel	TRUE, FALSE	TRUE
	fL	0, 0.5, 1	—
	adjust	0.5, 1, 2	—

Resultados y métricas de evaluación

La Tabla 6 presenta la comparación de los cinco modelos en términos de Exactitud Global (OA), Coeficiente Kappa y F1-Score ponderado, ordenados de mayor a menor rendimiento.

Table 6: Comparación de los cinco modelos – conjunto de prueba (384 píxeles).

Modelo	OA (%)	Kappa	F1-Score (w)
KNN	98.96	0.9813	0.9910 ← mejor
ANN	98.96	0.9811	0.9899
SVM	97.40	0.9536	0.9795
Decision Tree	97.40	0.9532	0.9777
Naive Bayes	94.79	0.9085	0.9600

La Figura 2 muestra visualmente la comparación de las tres métricas para los cinco modelos.

Comparación de Modelos — Cobertura del Suelo (Sesquile) Overall Accuracy, Kappa y F1-Score ponderado (%)




Figure 2: Comparación de OA, Kappa y F1-Score ponderado (%) para los cinco clasificadores evaluados sobre el conjunto de prueba.

La Tabla 7 y la Figura 3 detallan el F1-Score por clase y modelo, evidenciando que **agua** y **nube** son clasificadas perfectamente ($F1 = 1.000$) por la mayoría de los modelos, mientras que **urbana** presenta el rendimiento más bajo en todos los clasificadores debido al desbalance severo del dataset.

Table 7: F1-Score por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	0.997	1.000	1.000	0.997	0.986
nube	1.000	1.000	1.000	1.000	0.976
urbana	0.400	0.714	0.444	0.727	0.385
vegetacion	0.976	0.990	0.976	0.990	0.953




Figure 3: Mapa de calor del F1-Score por clase y modelo. Los tonos rojos indican bajo rendimiento y los verdes indican rendimiento óptimo. La clase **urbana** concentra las mayores dificultades en todos los modelos.

Análisis de las matrices de confusión

La Figura 4 presenta las matrices de confusión de los cinco modelos sobre el conjunto de prueba. Se observa que los errores de clasificación se concentran casi exclusivamente en la clase **urbana**, donde todos los modelos presentan dificultades para distinguirla de **vegetacion** debido al escaso número de muestras de entrenamiento disponibles (27 registros).




Figure 4: Matrices de confusión de los cinco clasificadores. Las filas representan la clase predicha y las columnas la clase real. Los valores en la diagonal corresponden a clasificaciones correctas.

Análisis del Árbol de Decisión

La Figura 5 muestra la estructura del Árbol de Decisión óptimo ($cp=0.001$). La primera partición se realiza sobre la banda B06 con umbral 0.066, separando el agua del resto de coberturas. La segunda división utiliza B02 para aislar las nubes ($B02 \geq 0.22$). Las ramas posteriores emplean combinaciones de B02, B03, B04 y B12 para discriminar entre vegetación y zona urbana.




Figure 5: Estructura del Árbol de Decisión óptimo (primeros niveles). Cada nodo indica la banda y umbral de partición, la clase predicha y la proporción de muestras en ese nodo.

La Figura 6 presenta la importancia relativa de cada banda espectral según el criterio Gini del Árbol de Decisión. Las bandas B05 (Red Edge, 0.167) y B04 (Rojo, 0.158) son las más discriminativas, lo cual tiene fundamento físico: B04 captura la absorción de clorofila que diferencia la vegetación del resto de coberturas, mientras que B05 (borde del rojo) refleja variaciones en el contenido de pigmentos vegetales. La banda B11 (SWIR, 0.100) es la menos influyente en este dataset.




Figure 6: Importancia relativa de las bandas espectrales Sentinel-2 según el criterio Gini del Árbol de Decisión óptimo.

Análisis del modelo KNN

La Figura 7 muestra la curva de Exactitud Global en función del número de vecinos K evaluada mediante validación cruzada. La curva es monótonamente decreciente desde $k=3$ ($OA=0.980$) hasta $k=31$ ($OA=0.910$), lo que indica que las firmas espectrales de cada clase forman *clústers compactos y homogéneos* en el espacio espectral de 8 dimensiones. Agregar más vecinos introduce ruido de clases adyacentes, degradando el rendimiento.




Figure 7: Curva de Exactitud Global vs número de vecinos K para el modelo KNN, evaluada mediante validación cruzada de 5 iteraciones. La línea roja discontinua indica el valor óptimo $k = 3$.

Selección del modelo para inferencia

Con base en los resultados obtenidos, se selecciona el modelo **KNN con $k = 3$** como clasificador para la inferencia final sobre el ráster completo. Los criterios de selección son:

- Mayor Coeficiente Kappa (0.9813), métrica más robusta que OA en presencia de desbalance de clases.
- Mayor F1-Score ponderado (0.9910), que refleja el rendimiento global considerando la distribución real de clases.
- Recall = 1.000 en la clase **urbana**, garantizando que ningún píxel urbano quede sin detectar en el mapa final.
- Clasificación perfecta de **agua y nube** ($F1 = 1.000$).