

Final Project: Monitoreo de la cobertura superficial del Embalse de Tominé mediante imágenes Sentinel-2

Juan Diego Romero, Eduardo de Brigard, Juan Parrales, Samuel Beltrán

21 de Mayo del 2026

1 Introducción

En los últimos años, el cambio climático y la actividad humana han tenido un impacto significativo sobre los ecosistemas hídricos y las coberturas terrestres de los Andes colombianos. Monitorear estos cambios es fundamental para comprender las consecuencias ambientales y su evolución con el tiempo. En este proyecto nos centramos en el **Embalse de Tominé**, ubicado en el municipio de Guatavita, Cundinamarca, el cual constituye una fuente de abastecimiento hídrico de importancia regional.

Mediante el uso del software QGIS e imágenes satelitales Sentinel-2 L2A, se busca analizar las coberturas del suelo (agua, vegetación, zona urbana y nube) para febrero de 2024, con el fin de clasificar y caracterizar la cobertura superficial del embalse de Tominé en el escenario de post-evento crítico provocado por el Fenómeno de El Niño.

2 Región de Interés (ROI) y Caso de Estudio

El caso de estudio seleccionado es el **Embalse de Tominé**, ubicado en el municipio de Guatavita, departamento de Cundinamarca, Colombia. Se trata de un embalse artificial de alta montaña andina con un paisaje heterogéneo que incluye cuerpos de agua, vegetación ripariana y tejido urbano disperso. El monitoreo se concentra en el escenario de post-evento crítico provocado por el Fenómeno de El Niño en el primer trimestre de 2024.

Ubicado en las coordenadas aproximadas **N 4.99°**, **O 73.82°** (WGS 84 / UTM zona 18N, EPSG:32618).

3 Metodología

El flujo metodológico se estructuró de manera independiente a las herramientas tradicionales de un software GIS, utilizando un pipeline automatizado en Python para el procesamiento numérico y el entrenamiento de los modelos de aprendizaje supervisado.

3.1 Fase 1: Definición del Problema y Adquisición de Datos

- **Fecha de análisis:** Escenario de post-evento crítico (12 de febrero de 2024).
- **Fuente de datos:** Imágenes ópticas multiespectrales Sentinel-2 L2A (ESA Copernicus).




Figure 1: Panel del Navegador de QGIS mostrando las bandas Sentinel-2 L2A cargadas para el escenario post-evento (2024-02-12) y la capa vectorial de polígonos de entrenamiento corregida.

Las bandas descargadas abarcan resoluciones espaciales de 10 m (B02, B03, B04, B08) y 20 m (B05, B06, B11, B12), en formato GeoTIFF de reflectancia superficial (Level-2A) bajo el sistema de referencia espacial WGS 84 / UTM zona 18N (EPSG:32618).

La Región de Interés (ROI) fue acotada geográficamente para optimizar el procesamiento computacional. Dentro de esta zona, se digitalizaron manualmente polígonos de entrenamiento distribuidos en **4 clases oficiales**: agua, vegetacion, nube

y urbano. La clase **roca** fue descartada debido a que los suelos desnudos y las playas expuestas por la sequía presentaban una respuesta espectral que se confundía con el tejido urbano, decidiéndose agruparlos para evitar ruido en las matrices de confusión.

Distribución de polígonos de entrenamiento

Table 1: Polígonos de entrenamiento por clase de cobertura.

Clase	Polígonos	Descripción
agua	3	Cuerpos de agua abiertos y profundos en el centro del embalse
vegetacion	4	Parches extensos de bosques andinos y pastizales
nube	4	Áreas de nubosidad densa presentes en la escena
urbano	2	Cascos urbanos consolidados (Sesquilé y Guatavita)
Total	13	

Creación del dataset – Extracción de firmas espectrales

Se desarrolló un script de Python (`QGIS-Numerical.py`) utilizando las librerías `rasterio` y `geopandas` para automatizar la extracción de firmas espectrales de los píxeles puros contenidos en las geometrías vectoriales. El script realizó la reproyección al vuelo, el remuestreo bilineal de las bandas de 20 m a 10 m, y calculó mediante la transformación afín las coordenadas geográficas (EPSG:4326) de cada celda.

Como resultado del diseño de los polígonos, se generó el siguiente dataset para el escenario de post-evento:

Table 2: Dataset de entrenamiento generado para el post-evento.

Archivo	Fecha	Total Píxeles	Columnas
<code>datos_entrenamiento_sesquile_finales.tsv</code>	2024-02-12	2,349	11

Table 3: Conteo de píxeles por clase de cobertura del suelo.

Clase	Píxeles	Porcentaje (%)
vegetacion	1,049	44.66
agua	746	31.76
nube	343	14.60
urbana	211	8.98
Total	2,349	100.0

3.2 Fase 2: Preprocesamiento y Entrenamiento de Modelos

Dataset final de entrenamiento

Para la Fase 2 se utilizó el dataset de entrenamiento generado en la Fase 1, denominado `datos_entrenamiento_sesquile_finales.tsv`, compuesto por **2,349 registros** y 11 columnas (Latitude, Longitude, B02, B03, B04, B05, B06, B08, B11, B12, `clase`), con la distribución de clases detallada en la Tabla 3.

El desbalance residual entre clases fue abordado mediante: aplicación de *pesos inversamente proporcionales a la frecuencia de clase* en el Árbol de Decisión, y *upsampling automático* en el `trainControl` de `caret` para los modelos KNN, SVM, ANN y Naive Bayes.

División train/test y normalización

El dataset fue dividido en un 80 % para entrenamiento (1,881 registros) y un 20 % para prueba (468 registros) mediante partición estratificada, garantizando que la proporción de clases se mantuviera en ambos subconjuntos. Para los modelos sensibles a la escala (KNN, SVM y ANN) se aplicó normalización *center + scale* calculada sobre el conjunto de entrenamiento y aplicada al conjunto de prueba.

Optimización de hiperparámetros (HPO)

Cada modelo fue sometido a una búsqueda exhaustiva de hiperparámetros mediante *GridSearchCV* con validación cruzada de 5 iteraciones (*5-fold CV*). La Tabla 4 resume los hiperparámetros explorados y los valores óptimos encontrados para cada arquitectura.

Table 4: Hiperparámetros explorados y valores óptimos por modelo.

Modelo	Parámetro	Valores explorados	Óptimo
Decision Tree	cp	0.0001, 0.001, 0.005, 0.01, 0.05, 0.1	0.1000
KNN	k	3, 5, 7, 9, 11, 15, 21, 31	3
SVM	C	0.1, 1, 10	10
	sigma	0.01, 0.1, 1	1.00
ANN	size	5, 10, 20, 100	10
	decay	0.001, 0.01, 0.1	0.010
Naive Bayes	usekernel	TRUE, FALSE	TRUE
	fL	0, 0.5, 1	—
	adjust	0.5, 1, 2	—

Resultados y métricas de evaluación

La Tabla 5 presenta la comparación de los cinco modelos en términos de Exactitud Global (OA), Coeficiente Kappa y F1-Score ponderado, ordenados de mayor a menor rendimiento.

Table 5: Comparación de los cinco modelos – conjunto de prueba (468 píxeles).

Modelo	OA (%)	Kappa	F1-Score (w)
ANN	98.93	0.9841	0.9895 ← mejor
KNN	98.72	0.9810	0.9875
SVM	98.08	0.9714	0.9810
Decision Tree	96.15	0.9433	0.9632
Naive Bayes	95.09	0.9276	0.9530

La Figura 2 muestra visualmente la comparación de las tres métricas para los cinco modelos.




Figure 2: Comparación de OA, Kappa y F1-Score ponderado (%) para los cinco clasificadores evaluados sobre el conjunto de prueba.

La Tabla 6 y la Figura 3 detallan el F1-Score por clase y modelo. Con el dataset balanceado todas las clases muestran un rendimiento notablemente superior, especialmente **urbana** que alcanzó valores de F1 entre 0.821 y 0.943. Las clases **agua** y **nube** mantienen clasificación perfecta en todos los modelos.

Table 6: F1-Score por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	0.997	1.000	1.000	1.000	0.986
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.821	0.933	0.897	0.943	0.804
vegetacion	0.956	0.985	0.978	0.988	0.944

Las Tablas 7 y 8 desglosan la Precisión y el Recall por clase y modelo, permitiendo identificar dónde cada clasificador comete errores de comisión (baja precisión) o de omisión (bajo recall).

Table 7: Precisión por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	1.000	1.000	1.000	1.000	1.000
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.736	0.875	0.867	0.911	0.709
vegetacion	0.980	1.000	0.985	0.995	0.965

Table 8: Recall por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	0.993	1.000	1.000	1.000	0.973
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.929	1.000	0.929	0.976	0.929
vegetacion	0.933	0.971	0.971	0.981	0.923




Figure 3: Mapa de calor del F1-Score por clase y modelo. Los tonos verdes indican rendimiento óptimo. La clase **urbana** presenta el mayor nivel de dificultad aunque con mejoras significativas respecto al dataset sin balancear.

Análisis de las matrices de confusión

La Figura 4 presenta las matrices de confusión de los cinco modelos sobre el conjunto de prueba (468 píxeles). ANN obtiene el mejor desempeño global, clasificando correctamente 41 de los 48 píxeles urbanos reales con solo 4 falsos positivos. KNN detecta todos los píxeles urbanos ($\text{Recall} = 1.0$) pero genera más falsos positivos (6). Los errores residuales se concentran en confusiones entre **urbana** y **vegetacion**, esperadas dado que algunas zonas de vegetación dispersa presentan firmas espectrales similares a superficies construidas en el contexto del post-evento. Las clases **agua** y **nube** se clasifican perfectamente en todos los modelos.




Figure 4: Matrices de confusión de los cinco clasificadores. Las filas representan la clase predicha y las columnas la clase real. Los valores en la diagonal corresponden a clasificaciones correctas.

Análisis del Árbol de Decisión

La Figura 5 muestra la estructura del Árbol de Decisión óptimo ($cp = 0.1$). Con el dataset balanceado el HPO seleccionó un cp mayor, resultando en un árbol más simple y generalizable de solo 4 niveles. La primera partición se realiza sobre la banda B06 con umbral 0.066, separando perfectamente el agua. La segunda división utiliza B02 con umbral 0.25 para aislar las nubes. Las hojas finales clasifican urbana y vegetación usando B02 con umbral 0.062.




Figure 5: Estructura del Árbol de Decisión óptimo. Cada nodo indica la banda y umbral de partición, la clase predicha y la proporción de muestras en ese nodo.

La Figura 6 presenta la importancia relativa de cada banda espectral según el criterio Gini. Las bandas B05 (Red Edge, 0.168) y B04 (Rojo, 0.157) son las más discriminativas: B04 captura la absorción de clorofila que diferencia la vegetación, mientras que B05 refleja variaciones en pigmentos vegetales. La banda B11 (SWIR, 0.100) es la menos influyente.




Figure 6: Importancia relativa de las bandas espectrales Sentinel-2 según el criterio Gini del Árbol de Decisión óptimo.

Análisis del modelo KNN

La Figura 7 muestra la curva de Exactitud Global en función de K. Con el dataset balanceado la curva presenta una forma de U suavizada con mínimo local alrededor de $k = 9$ y leve recuperación hacia $k = 15$, reflejando mayor variabilidad en el espacio espectral. Sin embargo, $k = 3$ sigue siendo el valor óptimo, confirmando que los clústers espectrales son suficientemente compactos.




Figure 7: Curva de Exactitud Global vs número de vecinos K para el modelo KNN, evaluada mediante validación cruzada de 5 iteraciones. La línea roja discontinua indica el valor óptimo $k = 3$.

Selección del modelo para inferencia

Con base en los resultados obtenidos, se selecciona el modelo **ANN con 10 neuronas y $\text{decay} = 0.01$** como clasificador para la inferencia final sobre el ráster completo. Los criterios de selección son:

- Mayor Coeficiente Kappa (0.9841), métrica más robusta que OA ante desbalance de clases.
- Mayor F1-Score ponderado (0.9895), reflejo del rendimiento global considerando la distribución real de clases.
- Mayor F1 en clase **urbana** (0.943), el mejor resultado obtenido por cualquier modelo en la clase más difícil del dataset.
- Clasificación perfecta de **agua y nube** ($F1 = 1.000$).
- Exactitud Global de 98.93 % sobre 468 píxeles de prueba no vistos durante el entrenamiento.

3.3 Fase 3: Inferencia sobre el Ráster Completo y Mapa Temático

Pipeline de inferencia

Una vez seleccionado el modelo ANN como clasificador óptimo, se desarrolló un script en R utilizando el paquete **terra** para aplicar la inferencia sobre la escena Sentinel-2 completa del 12 de febrero de 2024. El pipeline ejecutó los siguientes pasos:

1. Carga automática de las 8 bandas GeoTIFF desde la carpeta de origen mediante detección por nombre de banda.
2. Remuestreo bilineal de las bandas de 20 m (B05, B06, B11, B12) a la cuadrícula de 10 m de la banda de referencia B02.
3. Construcción del stack multibanda ($1,688 \text{ filas} \times 2,500 \text{ columnas} = 4,220,000$ píxeles).
4. Normalización *center + scale* aplicando el mismo objeto `pre_proc` calculado durante el entrenamiento, garantizando consistencia de escala.
5. Predicción píxel a píxel con el modelo ANN entrenado.
6. Codificación de clases a enteros: 1 = agua, 2 = nube, 3 = urbana, 4 = vegetacion.
7. Exportación del raster clasificado como GeoTIFF georreferenciado (INT1U, EPSG:32618).

Mapa temático de cobertura del suelo

El raster clasificado fue importado en QGIS y se aplicó una simbología discreta con colores diferenciados por clase. La Figura 8 presenta el mapa temático resultante con leyenda, escala y orientación.

Mapa de cobertura del Suelo - Embalse de Tominé
Febrero 2024




Figure 8: Mapa de cobertura del suelo del Embalse de Tominé – febrero 2024, generado mediante inferencia con el modelo ANN óptimo sobre la escena Sentinel-2 L2A completa. Verde: vegetación; Azul: agua; Blanco: nube; Rojo: zona urbana.

La Figura 9 muestra el mismo mapa con los polígonos de entrenamiento superpuestos, permitiendo verificar visualmente la coherencia entre las regiones de entrenamiento y las predicciones del modelo.

Mapa de cobertura del Suelo - Embalse de Tominé Febrero 2024




Figure 9: Mapa de cobertura del suelo con polígonos de entrenamiento superpuestos. Se observa la correspondencia espacial entre las regiones de entrenamiento digitalizadas en la Fase 1 y las clases predichas por el modelo ANN.

Cuantificación de áreas por clase

A partir del raster clasificado se calculó el área total de cada cobertura utilizando la resolución espacial de 10 m (100 m^2 por píxel). Los resultados se presentan en la Tabla 9.

Table 9: Área de cobertura del suelo clasificada – Embalse de Tominé, febrero 2024.

Clase	Píxeles	Área (ha)	Área (km ²)	%
vegetacion	2,050,105	1,640,518.0	16,405.2	48.58
agua	1,533,589	1,227,195.9	12,272.0	36.34
nube	465,038	372,128.9	3,721.3	11.02
urbana	171,268	137,050.7	1,370.5	4.06
Total	4,220,000	3,376,893.5	33,768.9	100

La vegetación constituye la cobertura dominante con 48.58 % de la escena (1,640,518 ha), seguida del agua con 36.34 % (1,227,196 ha). Este alto porcentaje de agua refleja el estado de recuperación del embalse en el escenario post-evento El Niño de febrero 2024, con niveles notablemente más altos que en la época seca de referencia. La nube ocupa el 11.02 % de la escena, mientras que la zona urbana representa el 4.06 % (137,051 ha) de la cobertura total. Cabe señalar que la clase urbana puede incluir suelos desnudos y playas expuestas del embalse cuya firma espectral es similar a la de las superficies construidas, lo cual constituye una limitación inherente al uso de cuatro clases de cobertura.

4 Resultados y Discusión

4.1 Mapas Temáticos

El mapa temático final de cobertura del suelo (Figura 8) muestra una escena dominada por vegetación andina densa, con el cuerpo de agua del embalse claramente identificado en la zona central. La distribución espacial de las clases es coherente con la realidad geográfica del área de estudio: la vegetación predomina en las laderas y zonas de montaña circundantes, el agua se concentra en el espejo del embalse y sus afluentes, las nubes aparecen como manchas dispersas típicas de la región andina en febrero, y la zona urbana se distribuye de manera fragmentada asociada a los núcleos de Sesquilé y Guatavita.

4.2 Estadísticas

La escena clasificada abarca un total de 33,768.9 km² a una resolución espacial de 10 m. El modelo ANN clasificó los 4,220,000 píxeles válidos de la escena sin píxeles sin datos (NoData=0), lo que confirma la cobertura completa del área de análisis. La vegetación y el agua representan conjuntamente el 84.92 % de la cobertura total, reflejando el carácter hídrico y ecológico del Embalse de Tominé y su entorno andino.

4.3 Discusión

Los resultados obtenidos demuestran la viabilidad del uso de modelos de aprendizaje automático supervisado para la clasificación de coberturas del suelo a partir de imágenes Sentinel-2 L2A. El modelo ANN con 10 neuronas y $\text{decay} = 0.01$, seleccionado tras un proceso exhaustivo de HPO con 5-fold CV, logró una Exactitud Global de 98.93 % y un Coeficiente Kappa de 0.9841 sobre el conjunto de prueba, confirmando su robustez para la tarea de clasificación multiclase en un entorno espectral complejo.

La principal limitación identificada es la similitud espectral entre la clase **urbana** y los suelos desnudos o playas expuestas del embalse bajo condiciones de sequía, lo que puede generar sobreclasificación de zonas construidas en áreas periféricas. Para estudios futuros se recomienda delimitar el área de inferencia al ROI definido y considerar la inclusión de índices espectrales complementarios como el NDVI o el NDWI para mejorar la separabilidad entre clases.

5 Conclusión

Este proyecto demostró la aplicabilidad de una cadena metodológica completa de GeoAI para el monitoreo de coberturas terrestres en el Embalse de Tominé, Guatavita, Cundinamarca. A lo largo de las tres fases se ejecutaron exitosamente: la adquisición y preprocesamiento de imágenes Sentinel-2 L2A, la construcción de un dataset de entrenamiento de 2,349 registros con firmas espectrales de 4 clases de cobertura, el entrenamiento y comparación de cinco arquitecturas de aprendizaje supervisado, y la generación del mapa temático georreferenciado mediante inferencia sobre la escena completa.

El modelo ANN con $k = 10$ neuronas y $\text{decay} = 0.01$ fue seleccionado como clasificador óptimo al lograr el mayor Coeficiente Kappa (0.9841), F1-Score ponderado (0.9895) y el mejor desempeño en la clase **urbana** ($F1 = 0.943$). El mapa final revela que la vegetación (48.58 %) y el agua (36.34 %) constituyen las coberturas dominantes de la escena en el escenario de post-evento El Niño de febrero 2024, con el embalse mostrando niveles de recuperación significativos respecto a la época seca de referencia de 2022.

El uso de herramientas de teledetección, SIG y aprendizaje automático demuestra su utilidad para el monitoreo ambiental de ecosistemas hídricos andinos, aportando información cuantitativa y espacialmente explícita sobre la dinámica de coberturas del suelo ante eventos climáticos extremos.