

EMBALSE DE TOMINÉ · GUATAVITA, CUNDINAMARCA

Monitoreo de Cobertura Superficial mediante Imágenes Sentinel-2

Clasificación supervisada de coberturas del suelo.

AUTORES

Juan Diego Romero

Eduardo de Brigard

Juan Parrales

Samuel Beltrán

CASO DE ESTUDIO

Región de Interés

LOCALIZACIÓN

Guatavita, Cundinamarca

N 4.99° · O 73.82° · WGS 84 / UTM 18N (EPSG:32618)

TIPO DE ÁREA

Embalse artificial de alta montaña andina

Paisaje heterogéneo: agua · vegetación ripariana · tejido urbano disperso

FECHA DE ANÁLISIS

12 de febrero de 2024

Escenario de post-evento crítico · Fenómeno de El Niño Q1 2024

IMPORTANCIA REGIONAL

Fuente de abastecimiento hídrico

Abastece Bogotá y municipios del altiplano cundiboyacense



Metodología en Tres Fases

01

Definición del Problema y Adquisición de Datos

Selección de ROI · Descarga de imágenes Sentinel-2 L2A · Digitalización de polígonos de entrenamiento · Extracción de firmas espectrales → dataset TSV

SEMANA 1

02

Preprocesamiento y Entrenamiento de Modelos

Normalización · HPO con 5-fold CV ·
Entrenamiento y comparación de 5 arquitecturas
· Evaluación: OA · Kappa · F1-Score

SEMANA 2

03

Inferencia y Mapa Temático

Aplicación del modelo óptimo sobre el ráster completo · Mapa temático georreferenciado en QGIS · Cuantificación de áreas por clase

SEMANA 3

FASE 1

Definición del Problema y Adquisición de Datos


Selección del evento · Imágenes Sentinel-2 L2A ·
Dataset de entrenamiento

01

Imágenes Sentinel-2 L2A

BANDA	NOMBRE	RESOLUCIÓN	UTILIDAD
B02	Azul	10 m	Discriminación agua / urbano
B04	Rojo	10 m	Absorción clorofila
B05	Red Edge	20 m	Pigmentos vegetales (más discriminativa)
B08	NIR	10 m	Estructura vegetal
B11	SWIR	20 m	Humedad del suelo

Nivel de procesamiento: Reflectancia superficial (L2A) · GeoTIFF · EPSG:32618



Dataset de Entrenamiento

TOTAL PÍXELES

2,349

11 columnas · archivo TSV


POLÍGONOS
DIGITALIZADOS

13

4 clases de cobertura

CLASE	POLÍGONOS	PÍXELES	%
vegetacion	4	1,049	44.66 %
agua	3	746	31.76 %
nube	4	343	14.60 %
urbano	2	211	8.98 %

Script `QGIS-Numerical.py` : reproyección · remuestreo bilineal ·
extracción de firmas espectrales con *rasterio* + *geopandas*



FASE 2

Preprocesamiento y Entrenamiento de Modelos

Normalización · HPO con 5-fold CV · 5 arquitecturas · OA
· Kappa · F1-Score

02

Cinco Arquitecturas de Aprendizaje Supervisado

DT Decision Tree Árbol jerárquico de umbrales espectrales. Revela qué bandas son más discriminativas.	KNN K-Nearest Neighbor Votación por mayoría entre los k vecinos más cercanos en el espacio espectral.	SVM Support Vector Machine Hiperplano de máximo margen entre clases en espacio de alta dimensión.	ANN Red Neuronal Artificial Capas de neuronas que aprenden relaciones no lineales entre bandas y coberturas. ÓPTIMO ↑	NB Naive Bayes Clasificador probabilístico (Bayes). Asume independencia entre bandas espectrales.
---	---	---	---	---

Optimización de Hiperparámetros

ESTRATEGIA

GridSearchCV · Validación cruzada 5-fold

División estratificada 80/20 · train: 1,881 px · test: 468 px

BALANCEO DE CLASES

Pesos inversamente proporcionales (DT) ·

Upsampling automático (KNN · SVM · ANN · NB)

Modelo	Parámetro	Valores explorados
Decision Tree	cp	0.0001, 0.001, 0.005, 0.01, 0.05, 0.1
KNN	k	3, 5, 7, 9, 11, 15, 21, 31
SVM	C	0.1, 1, 10
	sigma	0.01, 0.1, 1
ANN	size	5, 10, 20, 100
	decay	0.001, 0.01, 0.1
Naive Bayes	usekernel	TRUE, FALSE
	fL	0, 0.5, 1
	adjust	0.5, 1, 2

Parámetros óptimos encontrados

MODELO	PARÁMETRO	VALOR ÓPTIMO
Decision Tree	cp	0.1000
KNN	k (vecinos)	3
SVM	C / sigma	10 / 1.00
ANN	size / decay	10 neuronas / 0.010
Naive Bayes	usekernel	TRUE

Búsqueda exhaustiva sobre cuadrícula de hiperparámetros. El valor óptimo de ANN maximiza Kappa y F1-Score ponderado.

Comparación de Rendimiento · 468 píxeles de prueba

Modelo	EXACTITUD GLOBAL (OA)	Kappa	F1-Score
ANN	98.93 %	0.9841	0.9895
KNN	98.72 %	0.9810	0.9875
SVM	98.08 %	0.9714	0.9810
DT	96.15 %	0.9433	0.9632
NB	95.09 %	0.9276	0.9530

Las barras escalan desde 93 % para resaltar diferencias entre modelos · agua y nube: F1 = 1.000 en todos los modelos

F1-Score por Clase y Modelo

CLASE	DT	KNN	SVM	ANN★	NB
agua	0.997	1.000	1.000	1.000	0.986
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.821	0.933	0.897	0.943	0.804
Vegetación	0.956	0.985	0.978	0.988	0.944

La clase **urbana** presenta mayor dificultad por similitud espectral con suelos desnudos. **agua** y **nube** se clasifican perfectamente en todos los modelos.




Table 7: Precisión por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	1.000	1.000	1.000	1.000	1.000
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.736	0.875	0.867	0.911	0.709
vegetacion	0.980	1.000	0.985	0.995	0.965

Table 8: Recall por clase y modelo.

Clase	DT	KNN	SVM	ANN	NB
agua	0.993	1.000	1.000	1.000	0.973
nube	1.000	1.000	1.000	1.000	1.000
urbana	0.929	1.000	0.929	0.976	0.929
vegetacion	0.933	0.971	0.971	0.981	0.923

MODELO SELECCIONADO · FASE 2

ANN · 10 neuronas · decay = 0.01

98.93%

Exactitud Global (OA)

468 píxeles de prueba

0.9841

Coeficiente Kappa

Métrica más robusta ante desbalance

0.9895

F1-Score ponderado

Mejor en clase urbana F1 = 0.943

agua · F1 = 1.000

nube · F1 = 1.000

vegetacion · F1 = 0.988

urbana · F1 = 0.943

FASE 3

Inferencia sobre el Ráster Completo

Mapa temático georreferenciado · Cuantificación de áreas · GeoTIFF exportado

03

Pipeline de Inferencia · Script R (terra)

1 Carga de 8 bandas GeoTIFF

Detección automática por nombre de banda desde carpeta origen

2 Remuestreo bilineal 20 m → 10 m

Bandas B05, B06, B11, B12 a la cuadrícula de B02

3 Stack multibanda

1,688 filas × 2,500 columnas = **4,220,000 píxeles**

4 Normalización center + scale

Mismo objeto pre_proc del entrenamiento · garantiza consistencia de escala

5 Predicción píxel a píxel · ANN

Modelo entrenado en Fase 2 aplicado a toda la escena

6 Codificación de clases a enteros

1 = agua · 2 = nube · 3 = urbana · 4 = vegetacion

7 Exportación GeoTIFF georreferenciado

INT1U · EPSG:32618 · sin píxeles NoData (cobertura completa)

RESULTADO


Ráster categórico de una banda · resolución 10 m

Mapa de cobertura del Suelo - Embalse de Tominé
Febrero 2024


FASE 3 · RESULTADO

Mapa Temático de Cobertura del Suelo · Febrero 2024

■ Vegetación ■ Agua ■ Nube ■ Urbana



Cuantificación de Áreas por Clase



VEGETACIÓN + AGUA

84.92 % de la escena

Carácter hídrico y ecológico del embalse y entorno andino

ESCENA TOTAL CLASIFICADA

33,768.9 km² · resolución 10 m

4,220,000 píxeles · cobertura completa (NoData = 0)

NIVEL DE RECUPERACIÓN HÍDRICA

Significativo post-El Niño

Mayor nivel de agua que en época seca

DISCUSIÓN

Limitaciones Identificadas

SIMILITUD ESPECTRAL URBANO / SUELO DESNUDO

Las playas expuestas por la sequía presentan respuesta espectral similar a superficies construidas

Puede generar sobreclasificación de zonas construidas en áreas periféricas

CUATRO CLASES DE COBERTURA

La clase "roca" fue descartada y agrupada con urbano para evitar ruido en matrices de confusión

ÁREA DE INFERENCIA

La inferencia se aplicó sobre la escena completa, no delimitada al ROI estricto del embalse

TRABAJO FUTURO

Recomendaciones

ÍNDICES ESPECTRALES COMPLEMENTARIOS

Incluir NDVI, NDWI para mejorar la separabilidad entre clases espectralmente similares

DELIMITAR INFERENCIA AL ROI

Enmascarar el ráster de predicción al polígono del embalse para reducir errores de comisión

SERIE TEMPORAL MULTI-FECHA

Comparar coberturas antes, durante y después del evento El Niño para cuantificar la dinámica hídrica

Conclusiones

- 01 El pipeline completo de **GeoAI** (adquisición → preprocesamiento → entrenamiento → inferencia) demostró ser viable para monitoreo de coberturas en ecosistemas hídricos andinos.
- 02 El modelo **ANN** (10 neuronas, decay = 0.01) fue el clasificador óptimo con **Kappa = 0.9841** y **F1 ponderado = 0.9895** sobre el conjunto de prueba.
- 03 **Vegetación** (48.58 %) y **agua** (36.34 %) constituyen el 84.92 % de la cobertura total, reflejando el carácter hídrico y ecológico del embalse.
- 04 Los altos niveles de agua en febrero 2024 evidencian una **recuperación significativa** del embalse respecto a la época seca de referencia del año 2022.
- 05 La integración de **QGIS** · **Sentinel-2** · **Python** · **R** aporta información cuantitativa y espacialmente explícita para la gestión de eventos climáticos extremos.